

大模型RAG对话系统

RAG（Retrieval-Augmented Generation，检索增强生成）技术通过从外部知识库检索相关信息，并将其与用户输入合并后传入大语言模型（LLM），从而增强模型在私有领域知识问答方面的能力。EAS提供场景化部署方式，能快速构建与部署RAG对话系统，并支持灵活选择大语言模型和向量检索库。本文为您介绍如何部署RAG对话系统服务以及如何进行模型推理验证。

适用范围

本文适用于RAG版本0.4.0。旧版本请参考[PAI-RAG \(v0.3.x\)](#)。

步骤一：部署RAG服务

1. 登录[PAI控制台](#)，在页面上方选择目标地域，并在右侧选择目标工作空间，然后单击[进入EAS](#)。
2. 在推理服务页签，单击部署服务，然后在场景化模型部署区域，单击大模型RAG对话系统部署。
3. 在部署大模型RAG对话系统页面，配置如下关键参数：

- 版本选择：选择LLM分离式部署，仅部署RAG服务。



说明

LLM一体化部署会将RAG服务与大语言模型部署在同一个EAS服务实例中，如部署大模型会需要较高的资源规格，建议在使用小模型的情况下选择。

- RAG版本：`pai-rag:0.4.0`。
 - 资源信息：
 - 资源类型：选择公共资源。
 - 部署资源：RAG服务本身资源消耗较低。建议选择至少8核CPU和16 GB内存的规格，例如 `ecs.g6.2xlarge` 或 `ecs.g6.4xlarge`。
 - 向量检索库设置：
 - 版本类型：选择FAISS（构建本地向量库以便快速实践）。生产环境建议使用其他成熟的向量检索库，配置方式请参见[使用阿里云向量数据库](#)。
 - OSS地址：选择当前地域下已创建的OSS存储目录，用来存储上传的知识库文件。如果没有可选的存储路径，您可以参考[控制台快速入门](#)进行创建。
 - 专有网络：下文将需通过公网访问阿里云百炼的模型服务。请在此处配置VPC，开通公网NAT网关并配置SNAT条目，详情请参见[让EAS服务访问公网](#)。
4. 参数配置完成后，单击部署。服务部署时长通常约为5分钟，当服务状态变为运行中时，表示服务部署成功。

步骤二：快速体验知识库问答

在推理服务页签找到已部署的RAG服务，进入服务详情页，单击右上角的Web应用，进入WebUI页面。



2.1 配置大语言模型


单击左下角Settings > 模型，进入模型配置。这里以配置百炼qwen3-8b模型为例。更多模型配置说明参见[配置LLM模型](#)。



说明

- 阿里云百炼模型调用需单独计费，请参见[阿里云百炼计费项说明](#)。
- 调用百炼模型需为RAG服务配置有公网访问能力的专有网络。

- **模型ID**：对话时用于选择不同的模型。这里填写Qwen3-8B_bailian。
- **Endpoint URL**：下拉选择 https://dashscope.aliyuncs.com/compatible-mode/v1。
- **API Key**：参见[获取API Key](#)。
- **模型名称**：填写qwen3-8b。



2.2 添加知识库

系统已默认配置Embedding模型，可以直接创建知识库并上传文档。

1. **创建知识库**。单击左侧知识库，进入知识库页面，选择新建知识库。



以创建一个iphone16技术规格介绍的知识库为例，设置知识库名称为**iphone16介绍**，其他参数保持默认。单击创建。



2. **上传文件**。在文件管理页签，单击**上传文件**。示例文件：**iPhone 16 和 iPhone 16 Plus - 技术规格 - Apple (中国大陆).pdf**。




3. **查看知识库文件**。上传成功后，可单击**切片**，查看文档切片。也可以为文档设置访问权限等。

文件名	文件大小	上传时间	更新时间	状态	操作
iPhone 16 和 iPhone 16 Plus - 技术规格 - Apple (中国大陆).pdf	799.1 KB	2025-10-17 14:38:51	2025-10-17 14:38:51	✓ 解析成功	预览 切片 权限 元数据 源链接 重新解析 删除

首页 < Previous 1 Next > 末页

4. **检索测试**。切换到**检索测试**页签，输入查询内容（如 `iphone16` ），测试知识库检索。



2.3 知识库问答

1. 单击左侧**新建对话**，在对话页面上方选择模型，下方单击**知识库**，选择要使用的知识库（如**iphone16介绍**）单击**激活**，然后**保存**。



2. 在对话框内输入问题。问题示例：**iPhone 16 和 iPhone 16 Plus 采用了怎样的外观设计与机身材质？提供哪些配色选择？**



步骤三：更多问答模式体验

多模态问答（图文对话）

多模态问答需要为RAG服务配置OSS存储信息的环境变量用于存储上传的文件和图片，并使用多模态模型。

1. 为RAG服务配置OSS存储信息的环境变量。场景化部署不支持直接设置环境变量，在部署服务页面右上角选择切换为自定义部署（已创建的服务可通过更新操作进入部署页面），在环境信息区域增加如下环境变量：

- **FILE_STORE_TYPE**：设置为oss。
- **OSS_BUCKET**：填写OSS BUCKET名称。



说明

FILE_STORE_TYPE设置为oss后，**OSS_BUCKET**下会自动生成pairag_knowledgebases目录，存储上传的知识库文件和对话中上传的附件。不设置**FILE_STORE_TYPE**，默认会存储在挂载的OSS目录下。

- **OSS_ENDPOINT**：OSS访问地址，请参见OSS地域和Endpoint。如 `oss-cn-hangzhou.aliyuncs.com`，。
- **OSS_ACCESS_KEY_ID**、**OSS_ACCESS_KEY_SECRET**：拥有AliyunOSSFullAccess权限的AK和SK。

2. 配置多模态大语言模型（如Qwen-VL系列）。以qwen3-vl-plus为例，配置如下，需打开多模态模型开关。

编辑模型

填写模型配置信息后，点击保存。

模型ID *

qwen3-vl-plus_bailian

Endpoint URL *

https://dashscope.aliyuncs.com/compatible-mode/v1

API Key *

.....

模型名称 *

qwen3-vl-plus

多模态模型

☒

思考模型

☐

保存

3. 对话示例。上传一张包含多个动物的图片，然后提问：“图中有几个动物？”

qwen3-vl-plus_bailian

动物.png
已上传

图中有几个动物?

完成工具调用: image-parser (点击查看结果)

图中共有 6 只动物:

5只狗:

前景左侧: 1只金毛犬正在奔跑。

中间偏左: 1只柯基犬在奔跑。

中间偏右: 1只柯基犬在奔跑。

背景左侧: 1只柯基犬在远处奔跑。

背景右侧: 1只灰白相间的狗（可能是柴犬或类似品种）也在奔跑。

上传附件

输入您的问题...

深度思考

搜索

MCP

知识库

Agentic问答（MCP工具调用）

此模式利用模型思考和调用外部工具（如搜索、地图）的能力来回答复杂问题。
使用示例如下：

1. 配置支持思考的模型。模型配置中思考模型选项配置为打开。

编辑模型

×

填写模型配置信息后，点击保存。

模型ID *

Qwen3-8B_bailian

Endpoint URL *

https://dashscope.aliyuncs.com/compatible-mode/v1

API Key *

.....

模型名称 *

qwen3-8b

多模态模型

☐

思考模型

☒

保存

2. 配置阿里云通用搜索。详情请参见配置搜索。

- 通用搜索Endpoint：示例RAG服务部署在华东1（杭州），选择同地域接入点 `iqs-vpc.cn-hangzhou.aliyuncs.com`。
- Access Key ID与Access Key Secret：使用阿里云账号创建RAM用户并授权AliyunIQSFullAccess，访问方式选择使用永久 AccessKey 访问。

搜索配置

选择搜索引擎： 阿里云通用搜索 开通指南

通用搜索Endpoint iqs-vpc.cn-hangzhou.aliyuncs.com

AccessKey ID

AccessKey Secret

搜索结果条数(10)

保存搜索配置

3. 配置高德MCP。单击左下角Settings > MCP，参数配置如下。更多说明参见配置MCP。

- MCP 名称：amaps
- MCP 链接：https://mcp-server-amap-jitptfyoyw.cn-hangzhou.fcapp.run/sse
- MCP 类型：sse
- 对话测试。单击左侧新建对话，页面上方模型选择Qwen3-8B，在对话页面下方选择深度思考、搜索和MCP（激活amaps）。

问题示例：帮我规划下个月从杭州去上海旅游的一日游攻略和交通规划，两大一小，考虑天气情况。

Qwen3-32B_bailian

帮我规划下个月从杭州去上海旅游的一日游攻略和交通规划，两大一小，考虑天气情况。

思考完成

- 完成工具调用: amaps-maps_geo (点击查看结果)
- 完成工具调用: amaps-maps_geo (点击查看结果)
- 完成工具调用: amaps-maps_weather (点击查看结果)
- 完成工具调用: amaps-maps_weather (点击查看结果)

杭州到上海一日游攻略（两大一小）

一、交通规划

1. 杭州→上海

上传附件

输入您的问题...

深度思考

搜索

MCP

知识库



步骤四：评估RAG系统性能

RAG系统内置了评估模块，帮助您量化分析不同配置下的问答效果。以下是完整的评估流程：

1. 新建数据集。单击左侧边栏评估，进入评估页面，选择新建数据集。

PAI-RAG

知识库

应用

评估

对话

+ 新建对话

杭州至上海亲子游攻略

DonaldTrump总统就职

美国总统乔·拜登

美国总统

DonaldTrump美国总统

DonaldTrump 总统

酒驾检查

数据集 & 评估

评估数据集可以帮助你了解应用（AI助手）在不同数据集上的表现，从而选择最适合你需求的AI助手。

+ 新建数据集

数据集列表

数据集	类型	描述	样本数	实验数	创建时间	操作
GAIA	内置	GAIA评估	19	6	2025-09-19 14:16:36	

2. 导入样本。单击创建好的数据集，进入评估任务。在样本页签下，单击导入数据。

评估 > wiki-qa

概览: wiki-qa

关于wiki的问答对

样本

运行历史

运行设置

评估器设置

样本管理

管理您的问题/答案数据集。请选中样本运行实验。

运行实验(0项)

导入数据

数据要求: JSONL文件, 每行需包含 input(string), expected_output(string) 和 metadata(dict, 可选)

样本ID	问题	答案	操作
☐ 3644cc916632...	Was Lincoln chosen as a presidential candidate in 1860?	Yes	
☐ 57e02e67e89e...	Did lincoln have 18 months of schooling?	Yes	
☐ 7e88d67ac5e9...	Do scholars rank lincoln among the top three presidents?	Yes	
☐ 0e8b69992ba8...	Why did Lincoln issue the Emancipation Proclamation?	To free slaves	
☐ a18b7b598031...	Who was the general in charge at the Battle of Antietam?	General McClellan	
☐ 0db6724c11d9...	Did Lincoln win the election of 1860?	Yes	

首页

< Previous

1

2

Next >

末页

3. 新建运行配置。在运行设置页签下，单击新建配置，按需配置。

评估 > wiki-qa

概览: wiki-qa

关于wiki的问答对

样本

运行历史

运行设置

评估器设置

运行设置

应用运行时参数、模型、插件等设置

新建配置

名称	基模型	MCP	知识库	联网搜索	Agentic	护栏状态	操作
暂无数据							

4. 新建评估配置。在评估器设置页签下单击新建配置，按需选择配置和评估器类型。

评估 > wiki-qa

概览: wiki-qa

关于wiki的问答对

样本

运行历史

运行设置

评估器设置

评估器设置

进行评估实验的评分标准、评估器等配置

新建配置

名称	评估器类型	评估设置	操作
----	-------	------	----

5. 运行评估实验。在样本页签，勾选要评估的样本，单击运行实验，填写实验名称，并按需选择运行配置和评估配置。

PAI-RAG

知识库

应用

评估

对话

+ 新建对话

评估 > wiki-qa

概览: wiki-qa

关于wiki的问答对

样本

运行历史

运行设置

评估器设置

样本管理

管理您的问题/答案数据集。请选中样本运行实验。

数据要求: JSONL文件, 每行需包含 input(string), expected_output(string) 和 metadata(dict, 可选)

样本ID	问题	答案	操作
3644cc916632...	Was Lincoln chosen as a presidential candidate in 1860?	Yes	
57e02e67e89e...	Did lincoln have 18 months of schooling?	Yes	
7e88d67ac5e9...	Do scholars rank lincoln among the top three presidents?	Yes	
0e8b69992ba8...	Why did Lincoln issue the Emancipation Proclamation?	To free slaves	
a18b7b598031...	Who was the general in charge at the Battle of Antietam?	General McClellan	
0db6724c11d9...	Did Lincoln win the election of 1860?	Yes	
2de573f5545f...	Who assassinated Lincoln?	John Wilkes Booth	
b516c60627e7...	When did Lincoln first serve as President?	March 4, 1861	
b7df33e24c83...	Which countv was Lincoln born in?	Hardin County	

6. 查看评估结果。创建实验成功后，会自动跳转到实验详情页面。也可以直接切换到运行历史页签，选择目标实验进入。

PAI-RAG

知识库

应用

评估

对话

+ 新建对话

评估 > wiki-qa > 实验: batch-exp

实验: batch-exp

得分分布

状态分布

执行耗时

ID: 6e83eaff6fd546e8a23547678192a488 状态: 运行中 样本数: 20 平均得分: 0.00 展开详情

执行详情 (20)

样本ID	问题	状态	得分	耗时	操作
f8390a7ddc...	Was Abraham Lincoln the sixteenth President of the United States?...	等待中		0s	详情
0b12ab4851...	Did Lincoln sign the National Banking Act of 1863?...	等待中		0s	详情
d41ba1ab5a...	How many long was Lincoln's formal education?...	等待中		0s	详情
0a5c95ccc1...	When did Lincoln begin his political career?...	等待中		0s	详情
37e684e361...	What did The Legal Tender Act of 1862 establish?...	等待中		0s	详情

生产环境应用

使用阿里云向量数据库

PAI-RAG支持通过Elasticsearch、Milvus、Hologres、OpenSearch或RDS PostgreSQL构建向量检索库。

说明

Hologres、ElasticSearch、Milvus、RDS PostgreSQL支持通过内网或公网访问，推荐使用内网访问。

OpenSearch只支持通过公网访问。

ElasticSearch

准备Elasticsearch实例

如无Elasticsearch实例，请登录阿里云Elasticsearch控制台，参考如下配置创建。详情请参见创建阿里云Elasticsearch实例。

- **地域和可用区**：选择与EAS服务相同的地域。
- **专有网络**：选择与EAS服务一致的VPC，以便通过内网访问。
- **实例类型**：选择通用商业版。
- **场景初始化配置**：选择通用场景。

服务配置



重要

务必设置ElasticSearch实例允许自动创建索引：在Elasticsearch实例的**配置与管理** > **ES集群配置**页面，单击**修改配置**，将**自动创建索引**设置为**允许自动创建索引**。具体操作，请参见[配置YML参数](#)。

- **版本类型**：选择**Elasticsearch**。
- **私网地址/端口**：进入Elasticsearch实例详情页，在基本信息区域可获取私网地址和端口，格式为 `http://<私网地址>:<私网端口>`。
- **索引名称**：系统会根据输入执行不同操作。
 - **输入一个新名称**：EAS 将在部署时自动创建符合 PAI-RAG 要求的索引。



重要

阿里云Elasticsearch默认不允许自动创建索引。在Elasticsearch实例的**配置与管理** > **ES集群配置**页面，单击**修改配置**，更新YML文件配置，将**自动创建索引**设置为**允许自动创建索引**。具体操作，请参见[配置YML参数](#)。

- **输入已存在的名称**：EAS 将直接使用该索引。请确保该索引由PAI-RAG服务创建，以保证结构兼容。
- **账号、密码**：配置创建Elasticsearch实例时配置的登录名和密码。登录名默认为elastic。密码如忘记，可[重置实例访问密码](#)。
- **OSS地址**：请选择当前地域下已创建的OSS存储目录。通过挂载OSS路径实现知识库管理。

通过Kibana管理索引

Elasticsearch提供了索引管理功能，详情请参见[通过Kibana连接集群](#)。

Milvus

准备Milvus实例

如无Milvus实例，请登录[阿里云Milvus控制台](#)，参考如下配置创建。详情请参见[创建Milvus实例](#)。

- **地域和可用区**：选择与EAS服务相同的地域。
- **专有网络**：选择与EAS服务一致的VPC，以便通过内网访问。

服务配置

- **版本类型**：选择**Milvus**。
- **访问地址和代理端口**：登录[阿里云Milvus控制台](#)，单击目标实例名称进入**实例详情页**签，在**访问地址**区域，获取内网地址和**Proxy Port**。
- **账号**：默认为**root**。
- **密码**：创建Milvus实例时设置的用户密码，如忘记，可[重置实例密码](#)。
- **数据库名称**：可使用默认数据库**default**。也可以手动创建新的数据库，具体操作，请参见[管理Databases](#)。
- **Collection名称**：系统会根据输入执行不同操作。
 - **输入一个新名称**：EAS 将在部署时会自动创建符合 PAI-RAG 要求的 Collection。

- 输入已存在的**Collection**名称：EAS 将直接使用该 Collection。请确保该Collection由PAI-RAG服务创建，以保证结构兼容。
- **OSS地址**：选择已创建的OSS存储目录，用于存放和管理知识库文件。

通过Attu管理Milvus

Attu是Milvus的图形化管理工具，可以查看和管理向量数据。

1. 登录[阿里云Milvus控制台](#)，在实例列表页面中，单击目标实例名称。
 2. 在**安全配置**页签，单击**开启公网**，为Milvus实例开启公网访问。具体操作，请参见[网络访问与安全设置](#)。
配置完成后，实例状态变为升级中，大约持续1分钟。
 3. 开启成功后，返回**实例详情**页面，单击**Attu manager**。
 4. 在弹出的登录框中，输入用户名和密码，即可进入Attu管理界面。
 5. 登录成功后，可在Attu页面管理Collection。
- 更多使用说明，参见[Attu工具管理](#)。

完整实践文档可参见[通过阿里云Milvus与PAI搭建高效的检索增强对话系统](#)。

Hologres

请确认已[购买Hologres实例](#)。

- **版本类型**：选择**Hologres**。
- **调用信息**：配置为指定VPC的host信息。进入[Hologres管理控制台](#)的实例详情页，在**网络信息**区域单击指定**VPC**后的复制，获取域名 `:80` 前的host信息。
- **数据库名称**：配置为Hologres实例的数据库名称。如无，请参见[创建数据库](#)。
- **账号**：配置为已创建的自定义用户账号。具体操作，请参见[创建自定义用户](#)，其中选择**成员角色**选择**实例超级管理员 (SuperUser)**。
- **密码**：配置为已创建的自定义用户的密码。
- **表名称**：系统会根据输入执行不同操作。
 - 输入一个新名称：EAS 将在部署时会自动创建符合 PAI-RAG 要求的表。
 - 输入已存在的名称：EAS 将直接使用该表。请确保该表由PAI-RAG服务创建，以保证结构兼容。
- **OSS地址**：请选择当前地域下已创建的OSS存储目录。通过挂载OSS路径实现知识库管理。

OpenSearch

准备OpenSearch向量检索版实例

如无OpenSearch实例，请登录[OpenSearch控制台](#)，参考如下配置创建。详情请参见[购买OpenSearch向量检索版实例](#)。

- **商品版本**：选择**向量检索版**。
- **地域和可用区、专有网络**：OpenSearch只支持通过公网访问，无需与EAS服务一致。

服务配置

- **版本类型**：选择**OpenSearch**。
- **访问地址**：配置为OpenSearch向量检索版实例的公网访问地址。

②
说明

需为OpenSearch向量检索版实例开通公网访问功能，并将[EAS公网IP地址](#)添加为白名单。

- **实例id**：在[OpenSearch向量检索版](#)实例列表中获取实例ID。

- **用户名、密码**：配置为创建OpenSearch向量检索版实例时，输入的用户名和密码。
- **表名称**：需先创建满足要求的索引表。参见[配置实例](#)创建，关键参数如下：
 - 场景模板选择通用模板，字段配置导入如下配置文件。

字段配置文件

```
{
  "schema": {
    "summaries": {
      "parameter": {
        "file_compressor": "zstd"
      },
      "summary_fields": [
        "id",
        "embedding",
        "file_path",
        "file_name",
        "file_type",
        "node_content",
        "node_type",
        "doc_id",
        "text",
        "source_type"
      ]
    },
    "file_compress": [
      {
        "name": "file_compressor",
        "type": "zstd"
      },
      {
        "name": "no_compressor",
        "type": ""
      }
    ],
    "indexs": [
      {
        "index_fields": [
          {
            "boost": 1,
            "field_name": "id"
          },
          {
            "boost": 1,
            "field_name": "embedding"
          }
        ],
        "indexer": "aitheta2_indexer",
        "index_name": "embedding",
        "parameters": {
          "enable_rt_build": "true",
          "min_scan_doc_cnt": "20000",
          "vector_index_type": "Qc",
          "major_order": "col",
          "builder_name": "QcBuilder",
          "distance_type": "SquaredEuclidean",
          "embedding_delimiter": ",",
          "enable_recall_report": "true",
          "ignore_invalid_doc": "true",
          "is_embedding_saved": "false",
          "linear_build_threshold": "5000",
          "dimension": "1536",
          "update_index_name": "()"
        }
      }
    ]
  }
}
```

```

        "rt_index_params": "{\\"proxima.oswg.streamer.segment_size\\":2048}",
        "search_index_params": "{\\"proxima.qc.searcher.scan_ratio\\":0.01}",
        "searcher_name": "QcSearcher",
        "build_index_params": "
{"proxima.qc.builder.quantizer_class\\":\\"Int8QuantizerConverter\\",\\"proxima.qc.builder.quantize_by_
ntroid\\":true,\\"proxima.qc.builder.optimizer_class\\":\\"BruteForceBuilder\\",\\"proxima.qc.builder.thre
_count\\":10,\\"proxima.qc.builder.optimizer_params\\":
{"proxima.linear.builder.column_major_order\\":true},\\"proxima.qc.builder.store_original_features\\":
lse,\\"proxima.qc.builder.train_sample_count\\":3000000,\\"proxima.qc.builder.train_sample_ratio\\":0.5}

    },
    "index_type": "CUSTOMIZED"
  },
  {
    {
      "has_primary_key_attribute": true,
      "index_fields": "id",
      "is_primary_key_sorted": false,
      "index_name": "id",
      "index_type": "PRIMARYKEY64"
    },
    {
      "index_fields": "file_path",
      "index_name": "file_path",
      "index_type": "STRING"
    },
    {
      "index_fields": "file_name",
      "index_name": "file_name",
      "index_type": "STRING"
    },
    {
      "index_fields": "file_type",
      "index_name": "file_type",
      "index_type": "STRING"
    },
    {
      "index_fields": "node_content",
      "index_name": "node_content",
      "index_type": "STRING"
    },
    {
      "index_fields": "node_type",
      "index_name": "node_type",
      "index_type": "STRING"
    },
    {
      "index_fields": "doc_id",
      "index_name": "doc_id",
      "index_type": "STRING"
    },
    {
      "index_fields": "text",
      "index_name": "text",
      "index_type": "STRING"
    },
    {
      "index_fields": "source_type",
      "index_name": "source_type",
      "index_type": "STRING"
    }
  },
  "attributes": [
    {

```



```

    "file_compress": "no_compressor",
    "field_name": "id"
  },
  {
    "file_compress": "no_compressor",
    "field_name": "embedding"
  },
  {
    "file_compress": "no_compressor",
    "field_name": "file_path"
  },
  {
    "file_compress": "no_compressor",
    "field_name": "file_name"
  },
  {
    "file_compress": "no_compressor",
    "field_name": "file_type"
  },
  {
    "file_compress": "no_compressor",
    "field_name": "node_content"
  },
  {
    "file_compress": "no_compressor",
    "field_name": "node_type"
  },
  {
    "file_compress": "no_compressor",
    "field_name": "doc_id"
  },
  {
    "file_compress": "no_compressor",
    "field_name": "text"
  },
  {
    "file_compress": "no_compressor",
    "field_name": "source_type"
  }
],
"fields": [
  {
    "compress_type": "uniq",
    "field_type": "STRING",
    "field_name": "id"
  },
  {
    "user_defined_param": {
      "multi_value_sep": ","
    },
    "multi_value": true,
    "compress_type": "uniq",
    "field_type": "FLOAT",
    "field_name": "embedding"
  },
  {
    "compress_type": "uniq",
    "field_type": "STRING",
    "field_name": "file_path"
  },
  {
    "compress_type": "uniq",

```

```
    "field_type": "STRING",
    "field_name": "file_name"
  },
  {
    "compress_type": "uniq",
    "field_type": "STRING",
    "field_name": "file_type"
  },
  {
    "compress_type": "uniq",
    "field_type": "STRING",
    "field_name": "node_content"
  },
  {
    "compress_type": "uniq",
    "field_type": "STRING",
    "field_name": "node_type"
  },
  {
    "compress_type": "uniq",
    "field_type": "STRING",
    "field_name": "doc_id"
  },
  {
    "compress_type": "uniq",
    "field_type": "STRING",
    "field_name": "text"
  },
  {
    "compress_type": "uniq",
    "field_type": "STRING",
    "field_name": "source_type"
  }
],
"table_name": "abc"
},
"extend": {
  "description": [],
  "vector": [
    "embedding"
  ],
  "embedding": []
}
```

- 索引结构中，向量维度要与知识库向量模型使用的向量维度保持一致，距离类型建议选择InnerProduct。

管理索引表与数据

- 登录[阿里云OpenSearch向量检索版控制台](#)，单击已创建的实例ID，进入实例详情页面。
- 进入表管理页面，对索引表进行管理操作。详情请参见[表管理](#)。

OpenSearch向量检索版 / 实例列表 / ha-cn-实例ID

← ha-cn-实例ID

实例详情
表管理
向量管理
查询测试
添加数据
删除数据

添加表

表名称	状态	全量数据源	表大小	全量生效版本	全量生效时间	增量生效时间	数据更新源数	备注	操作
test_index	使用中	API	63.66KB	1724917705	2024-08-29 15:51:23	2024-09-03 11:06:01	2	暂无	查看 编辑 重建索引 删除
test_index_2	使用中	API	8.70KB	1725006839	2024-08-30 16:38:23	2024-09-03 11:09:06	2	暂无	查看 编辑 重建索引 删除

- 进入向量管理页面，进行查询测试、添加或删除数据。详情请参见[向量管理](#)。

RDS PostgreSQL

准备RDS PostgreSQL实例

1. 如无RDS PostgreSQL实例，[点此打开RDS实例创建页面](#)，配置如下关键参数后，按照控制台操作指引完成支付和开通操作。详情请参见[创建RDS PostgreSQL实例](#)。
 - 引擎：选择**PostgreSQL**。
 - VPC：选择与EAS服务一致的VPC，以便通过内网访问。
 - 高权限账号：在更多配置区域，配置高权限账号。选择**立即设置**，并配置数据库账号和密码。
2. 创建数据库。
 - i. 单击已创建的实例名称，在左侧导航栏单击**数据库管理**，并单击**创建数据库**。
 - ii. 在创建数据库配置面板中，配置数据库（DB）名称，授权账号选择已创建的高权限账号，其他参数配置说明，请参见[创建账号和数据库](#)。
 - iii. 参数配置完成后，单击**创建**。


服务配置

请确认已[创建RDS PostgreSQL实例](#)。

- **版本类型**：选择**RDS PostgreSQL**。
- **主机地址**：配置为RDS PostgreSQL实例的内网地址，您可以前往[云数据库RDS PostgreSQL控制台](#)页面，在RDS PostgreSQL实例的数据库连接页面进行查看。
- **端口**：默认为5432，请根据实际情况填写。
- **数据库**：数据库的授权账号需为高权限账号，操作请参见[创建账号和数据库](#)。同时需为数据库安装插件vector和jieba。
- **表名称**：自定义配置数据库表名称。
- **账号、密码**：配置为创建数据库时的授权账号和密码。如何创建高权限账号，请参见[创建账号和数据库](#)，其中账号类型选择高权限账号。
- **OSS地址**：请选择当前地域下已创建的OSS存储目录。通过挂载OSS路径实现知识库管理。

RDS PostgreSQL数据库管理

1. 访问[RDS实例列表](#)，切换到实例所在地域，然后单击实例名称，进入实例详情页面。
2. 在左侧导航栏选择**数据库管理**，然后单击目标数据库操作列下的**SQL查询**。
3. 输入**数据库账号**和**数据库密码**，即您在创建RDS PostgreSQL时设置的高权限账号和密码，然后单击**登录**。
4. 登录成功后，在已登录数据库实例中查询导入的知识库列表。



附录：WebUI配置说明

配置LLM模型

单击左下角**Settings > 模型**，进入模型配置。在LLM页签可添加多个模型。

说明


如果是一体化部署，会自动生成一条模型配置记录。还可以继续添加其他来源的模型。

- **模型ID**：区分不同模型配置。
- **Endpoint URL**：单击选择OpenAI或者阿里云百炼的URL，也可直接填写其他模型服务的URL。

说明

- 阿里云百炼模型调用需单独计费，请参见[阿里云百炼计费项说明](#)。
- 如果使用EAS部署的模型服务，在服务实例的基本信息区域单击查看调用信息。注意URL结尾需添加/v1。
 - 公网地址访问LLM服务需为RAG服务配置有公网访问能力的专有网络。
 - VPC地址访问LLM服务需RAG服务与LLM服务处于同一专有网络内。

- **API Key**：阿里云百炼参见[获取API Key](#)填写。EAS服务则填写调用信息中的Token。
- **模型名称**：根据实际情况填写。如果是EAS部署的LLM服务且推理引擎为**vLLM**，请务必填写具体的模型名称。可通过 `/v1/models` 接口获取模型名称。对于其他部署模式，则只需将模型名称设置为 `default` 即可。
- **多模态模型**：如果是多模态模型，则勾选，否则不勾选（默认不勾选）。
- **思考模型**：有思考与非思考两种模式的模型，可通过该选项来控制是否思考。默认不勾选。



配置成功后建议先测试模型配置。单击左侧**新建对话**，在对话页面上方选择模型进行对话测试。



配置搜索

单击左下角**Settings** > **搜索**，进入搜索配置。支持Tavily搜索和阿里云通用搜索。

Tavily搜索

访问 [Tavily 官网](#)注册账户，并获取API Key。

搜索配置

选择搜索引擎：

Tavily 搜索

开通指南

Tavily API Key

.....

搜索结果条数(10)

保存搜索配置

阿里云通用搜索

通用搜索Endpoint：

- 优先推荐使用VPC接入，不支持VPC接入的地域请使用公网地址，具体接入地址请参见[服务接入点](#)。
- 使用公网地址接入，请确保已为RAG服务[配置有公网访问能力的专有网络](#)。

Access Key ID与Access Key Secret：

- 使用阿里云账号[创建RAM用户并授权](#)，访问方式选择使用永久 **AccessKey** 访问。用户创建成功后，复制**Access Key ID**与**Access Key Secret**填入。
- 需要为该用户授予权限AliyunIQSFullAccess，否则使用搜索时会报错。

搜索配置

选择搜索引擎：

阿里云通用搜索

开通指南

通用搜索Endpoint

iqs-vpc.cn-hangzhou.aliyuncs.com

AccessKey ID

.....

AccessKey Secret

.....

搜索结果条数(10)

保存搜索配置

配置MCP

单击左下角**Settings > MCP**，进入MCP配置。

- **MCP链接**：MCP 服务的完整访问端点 URL。
- **MCP类型**：支持SSE / STDIO / HTTP。
- **Bearer Token**：（可选）使用Bearer令牌认证，需填写有效的访问令牌。

添加MCP

×

填写MCP配置信息后，点击保存。

MCP 名称 *

amaps

MCP 链接 *

https://mcp-server-amap-jitptfyoyw.cn

MCP 类型 *

sse

Bearer Token

Bearer Token (可选)

默认启用

☒

添加